ПРОЕКТ СИСТЕМЫ · ВЕРСИЯ 1 · 27 СЕНТЯБРЯ 2026

Мать лемматизаторов

Единый лемматизатор для всех языков списка Glottolog: он определяет язык каждого фрагмента текста, приводит слова к леммам по готовым грамматическим правилам, если они есть, а для незнакомого языка находит родственные языки и выводит из их грамматик предварительную грамматику, опираясь на закономерности языковых изменений.

установленные знания: проверенные правила, трибанки, описанные грамматики

выведенные знания: перенесённые, индуцированные или реконструированные, всегда с оценкой уверенности

Обзор

На входе — произвольный текст на любом языке и в любой письменности. На выходе — тот же текст, где для каждого слова указана лемма, а также определённый язык, грамматика, по которой получена лемма, и уверенность. Все тексты проходят общий этап распознавания языка, после чего направляются в один из трёх уровней в зависимости от того, что системе известно о языке:

Уровень A · правила есть

Язык распознан, есть проверенная грамматика

Анализатор на правилах предлагает все возможные леммы, контекстная нейросетевая модель выбирает из них. Максимальная точность, каждое решение объяснимо.

Уровень B · язык известен, правил нет

Язык распознан, машиночитаемой грамматики нет

Правила извлекаются из грамматик в каталоге документов и индуцируются из текстов, затем компилируются в тот же формат правил.

Уровень C · неизвестный язык

Распознаватель отвергает все известные метки

Ближайшие родственники находятся по генеалогическому дереву; их грамматики переносятся через выученные звуковые соответствия, подгоняются к тексту и проверяются типологическими универсалиями.

Грамматики уровней B и C — предварительные. Они хранятся вместе с происхождением и оценкой уверенности, используются сразу, а на уровень A переводятся только после проверки: сначала автоматической, затем лингвистом. Каждый обработанный так язык улучшает работу системы для его соседей по дереву.

Схема архитектуры

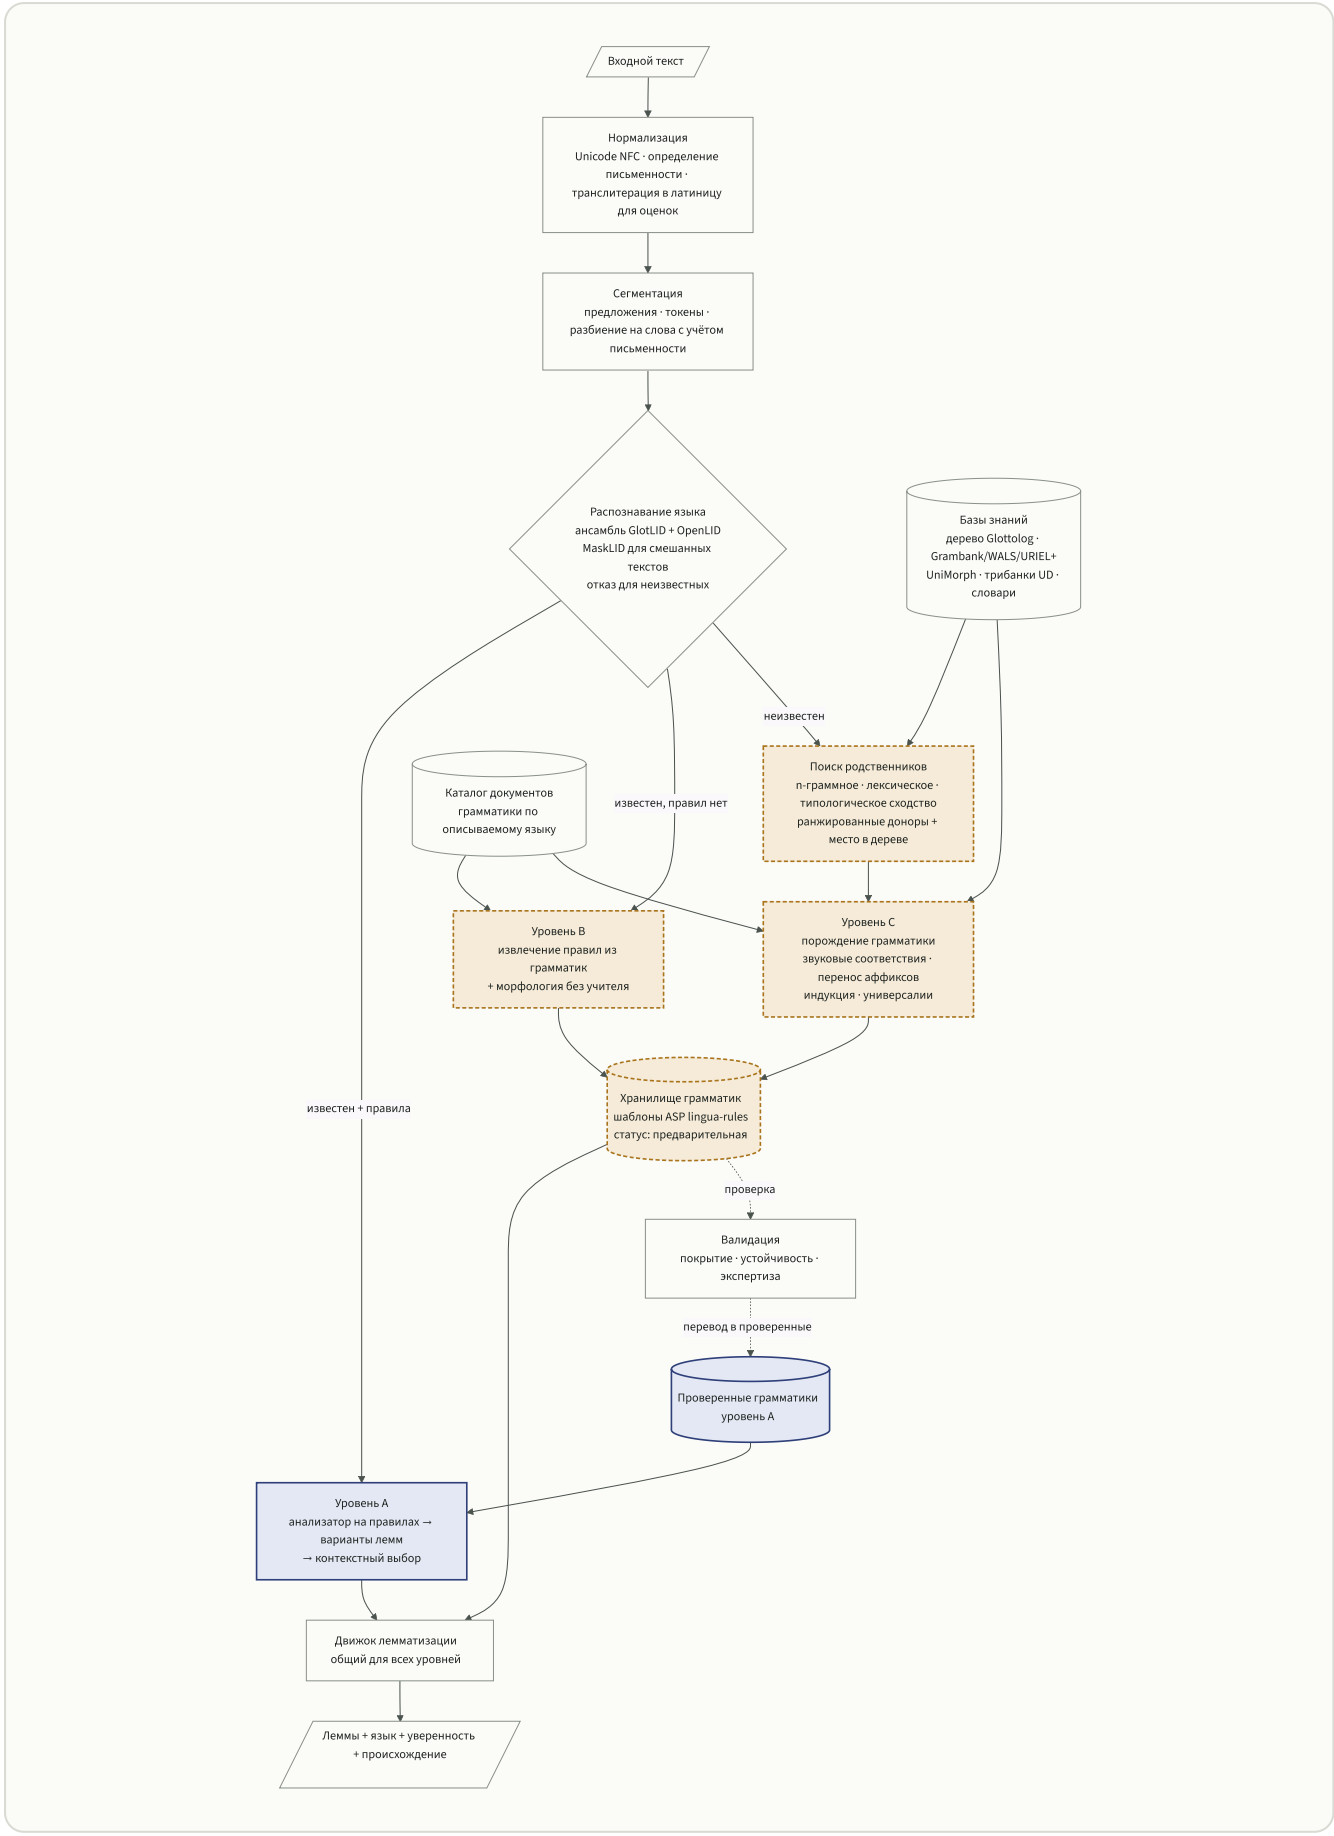


Рис. 1. Компоненты и потоки данных. Сплошной синий — проверенные знания; пунктирный охристый — выведенные знания с оценкой уверенности, ожидающие проверки.

Компоненты

КОМПОНЕНТ	ЗАДАЧА	МЕТОД
Нормализация	Сделать тексты из разных источников сопоставимыми	Unicode NFC, удаление символов нулевой ширины, определение письменности по свойству Unicode Script (ISO 15924), романизация (в духе uroman) только для оценки сходства, никогда для вывода
Сегментация	Предложения и словоформы	Правила для письменностей с пробелами; словарная/статистическая сегментация для письменностей без пробелов (тайская, китайская, японская)
Распознавание языка	Метка языка для каждого фрагмента или «неизвестен»	Ансамбль классификаторов fastText, обнаружение переключения кодов, откалиброванный отказ (раздел «Распознавание языка»)
Поиск родственников	Для неизвестного языка: доноры и место в дереве	n-граммное, лексическое (когнаты) и типологическое сходство, объединённые обученным ранжировщиком
Хранилище грамматик	Единый формат всех грамматик	Шаблоны парадигм и правил в формате ASP lingua-rules; у каждого правила — уверенность, происхождение и статус
Движок лемматизации	Словоформа → лемма в контексте	Анализатор на правилах порождает варианты; нейросетевая модель скриптов редактирования оценивает их в контексте; угадыватель обрабатывает незнакомые слова
Валидация	Решить, когда выведенным правилам можно доверять	Покрытие корпуса, устойчивость на бутстрэп-выборках, обратная генерация, отложенные проверки, очередь на экспертизу

Распознавание языка

Для каждого фрагмента распознавание отвечает на два вопроса: какой это известный язык — и не является ли он ни одним из них. Второй вопрос здесь важнее всего: классификатор с закрытым набором меток всегда выдаёт какую-то метку, даже для языка, которого никогда не видел.

Алгоритм

1. **Сначала письменность.** Основная письменность Unicode сужает набор кандидатов (кириллический текст не может быть на хинди). Письменность входит в метку, как в GlotLID (`kaz_Cyrl` и `kaz_Latn`).
2. **Классификация по закрытому набору.** GlotLID v3 (fastText, 2 102 метки «язык–письменность», обучен на 1 832 языках) возвращает k лучших меток с вероятностями. OpenLID-v3 добавляется вторым голосом, так как настроен на точность среди близкородственных языков. Вероятности

калибруются для каждой метки (температурное шкалирование на отложенных данных), чтобы пороги значили одно и то же для всех языков.

3. **Смешанные тексты.** Фрагменты оцениваются скользящим окном. MaskLID маскирует признаки доминирующего языка и заново классифицирует остаток — так без дополнительного обучения обнаруживается вкраплённый второй язык.
4. **Отказ для неизвестных.** Фрагмент помечается как *неизвестный*, если выполняется любое условие: откалиброванная максимальная вероятность ниже τ_p; энтропия распределения k лучших выше τ_H; текст нетипичен для победившей метки, т. е. его перплексия по символьным n-граммам под моделью этого языка намного выше перплексии собственных проверочных текстов языка (z-оценка выше τ_z). Третья проверка ловит самый опасный случай — уверенную, но ошибочную метку близкого родственника настоящего языка.
5. **Сглаживание по документу.** Соседние фрагменты редко меняют язык, поэтому метки сглаживаются простой скрытой марковской моделью по фрагментам (штраф за переключение); одиночные неуверенные переключения отменяются.

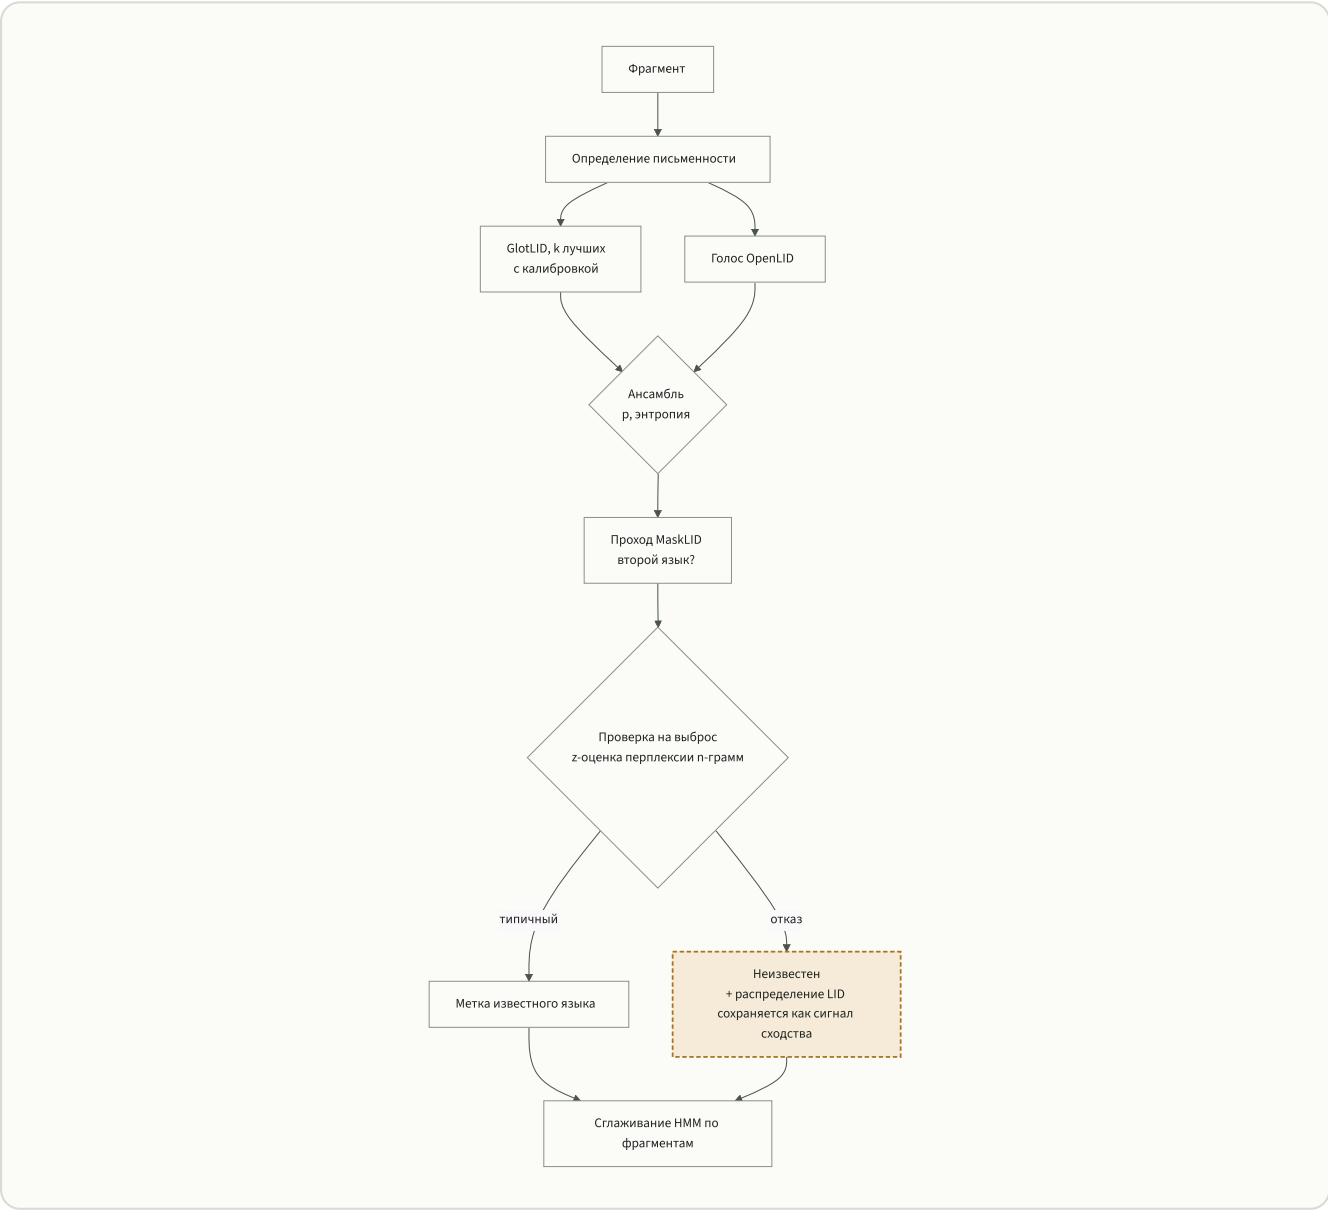


Рис. 2. Конвейер распознавания для одного фрагмента. Отвергнутый фрагмент сохраняет полное распределение вероятностей — это первый сигнал сходства при поиске родственников.

```
# распознавание языка для одного документа
def recognise(doc):
    segments = segment(normalise(doc))
    labels = []
    for seg in segments:
        script = dominant_script(seg)
        dist = ensemble(glotlid.topk(seg, 20), openlid.topk(seg, 20), allowed_script=script)
        dist = calibrate(dist)                                  # температура для каждой
метки
        top, p = dist.best()
        z = perplexity_zscore(seg, ngram_model[top])            # нетипичен для победившей
метки?
        if p < TAU_P or entropy(dist) > TAU_H or z > TAU_Z:
            labels.append(Unknown(posterior=dist, script=script))
        else:
            second = masklid(seg, dominant=top)                  # переключение кодов
            labels.append(Known(top, p, embedded=second))
    return hmm_smooth(labels, switch_penalty=SWITCH)
```

Поиск родственников неизвестного языка

Для неизвестного языка системе нужен небольшой набор языков-*доноров*, чьи грамматики можно перенести, и оценка места языка в генеалогическом дереве Glottolog. Ни один сигнал не надёжен сам по себе: общая лексика может быть заимствованной, похожее написание может отражать лишь общую орфографическую традицию. Поэтому ранжировщик объединяет четыре независимых сигнала, следуя подходу LangRank — обучению тому, какие признаки предсказывают успешный перенос.

СИГНАЛ	КАК ВЫЧИСЛЯЕТСЯ	ЧТО ОТРАЖАЕТ
Распределение LID	Отвергнутое распределение из этапа распознавания, агрегированное по всем фрагментам	Внешнее сходство; дёшево и доступно сразу
Профиль символьных n-грамм	Ранговое расстояние Кавнара–Тренкла («out-of-place») и косинусное расстояние профилей 1–5-грамм до эталонных корпусов языков-кандидатов	Фонотактику и орфографию
Лексическое родство (когнаты)	Самые частотные словоформы целевого текста выравниваются со словарями кандидатов (выравнивание SCA); оценка в духе LexStat вознаграждает *регулярно повторяющиеся* звуковые соответствия, а не случайное сходство; доля вероятных когнатов в базовой лексике	Генеалогическое родство; самый сильный сигнал при достаточном объёме текста
Типологический отпечаток	Признаки, оценённые по сырому тексту (среднее число морфов на слово по сегментации без учителя, доля префиксов и суффиксов, частота редупликации, признаки порядка слов по частотным служебным словам), сравниваются с векторами Grambank/URIEL+	Структурное сходство; полезно, когда родственники далёкие или неизвестны

Ранжировщик на градиентном бустинге (как в LangRank) объединяет сигналы с априорными данными (письменность, география языков-кандидатов, объём грамматики каждого кандидата) и возвращает ранжированный список доноров. Место в дереве оценивается как ближайший общий предок лучших доноров в Glottolog, взвешенный по их оценкам. Если ни один донор не проходит порог по когнатам, язык рассматривается как возможный изолят: тогда уровень C опирается только на индукцию без учителя и типологические априорные данные.

```
# ранжирование языков-доноров для неизвестного языка U
def find_relatives(U_text, posterior, candidates):
    freq_types = most_frequent_types(U_text, n=2000)
    for L in candidates:                                  # предварительно отобраны по
письменности, географии, LID
        f_post  = posterior.get(L, 0)
        f_ngram = out_of_place(ngram_profile(U_text), profile[L])
        f_cog   = lexstat_cognate_share(freq_types, lexicon[L])   # только регулярные
соответствия
        f_typo  = cosine(estimate_typology(U_text), grambank_vec[L])
        score[L] = ranker.predict([f_post, f_ngram, f_cog, f_typo, prior(L)])
    donors = top_k(score, k=5)
    position = weighted_lca(glottolog, donors, score)
    return donors, position, is_isolate(f_cog_max < TAU_COG)
```

Лемматизация по готовым правилам (уровень A)

Там, где есть проверенная грамматика, система сочетает точные правила со статистической моделью, учитывающей контекст. Правила гарантируют, что каждая лемма — допустимая форма языка; модель

выбирает между неоднозначными разборами (нем. *Weg* — существительное «путь» или частица *weg*, рус. «стали» — «сталь» или «стать»).

1. **Анализ.** Каждый токен проходит через анализатор на правилах (шаблоны парадигм и правила чередований из хранилища грамматик). Результат — набор вариантов разбора: лемма + часть речи + признаки.
2. **Проверка по словарю.** Варианты с леммой из словаря предпочтительнее; неизвестные леммы допускаются, но со штрафом.
3. **Незнакомые слова.** Угадыватель отсекает самые продуктивные аффиксы (продуктивность — число разных основ, с которыми встречен аффикс) и предлагает варианты лемм, ранжированные по соответствию парадигме.
4. **Выбор по контексту.** Нейросетевой лемматизатор на скриптах редактирования (подход Universal Lemmatizer и Stanza/UDPipe, обучен на Universal Dependencies) оценивает каждый вариант в предложении. Если есть хотя бы один вариант от правил, ответ ограничивается ими — модель не может выдумать несуществующее слово.

Язык известен, правил нет (уровень B)

Для большинства языков нашего каталога грамматика существует только в виде книги. Уровень B превращает эти книги и доступные тексты в правила.

1. **Поиск.** Из каталога документов берутся грамматики, очерки и учебники, у которых описываемый язык совпадает с целевым.
2. **Извлечение.** Локальная языковая модель читает таблицы парадигм и главы о морфологии и выдаёт структурированные правила: аффикс, позиция, признаки, условия, примеры. Глоссированные примеры (IGT) разбираются на пары «морфема — глосса» и используются как тесты. Исследования обучения по грамматикам (MTOB) показывают, что модели извлекают пользу в основном из примеров и таблиц, а не из текстовых объяснений, поэтому извлечение сосредоточено на них.
3. **Индукция.** Независимо сегментация без учителя (Morfessor FlatCat) и кластеризация парадигм по сырому тексту предлагают аффиксы и парадигмы.
4. **Согласование.** Извлечённые правила служат априорным знанием, индуцированная сегментация — свидетельством. Правила, подтверждённые текстом, получают высокую уверенность; правила, которые в тексте не проявляются, сохраняются с пометкой; частые необъяснённые закономерности становятся кандидатами в новые правила.
5. **Компиляция.** Результат записывается в хранилище грамматик в формате шаблонов lingua-rules, поэтому движок уровня A использует его без изменений.

Порождение грамматики неизвестного языка (уровень C)

Здесь система использует законы языковых изменений. Рабочее допущение — как в сравнительно-историческом методе: родственные языки происходят от общего предка, и различия между ними в

значительной мере *регулярны*. Если выучить регулярные соответствия между неизвестным языком и его родственниками, морфологию родственников можно отобразить на неизвестный язык и затем проверить по его текстам.

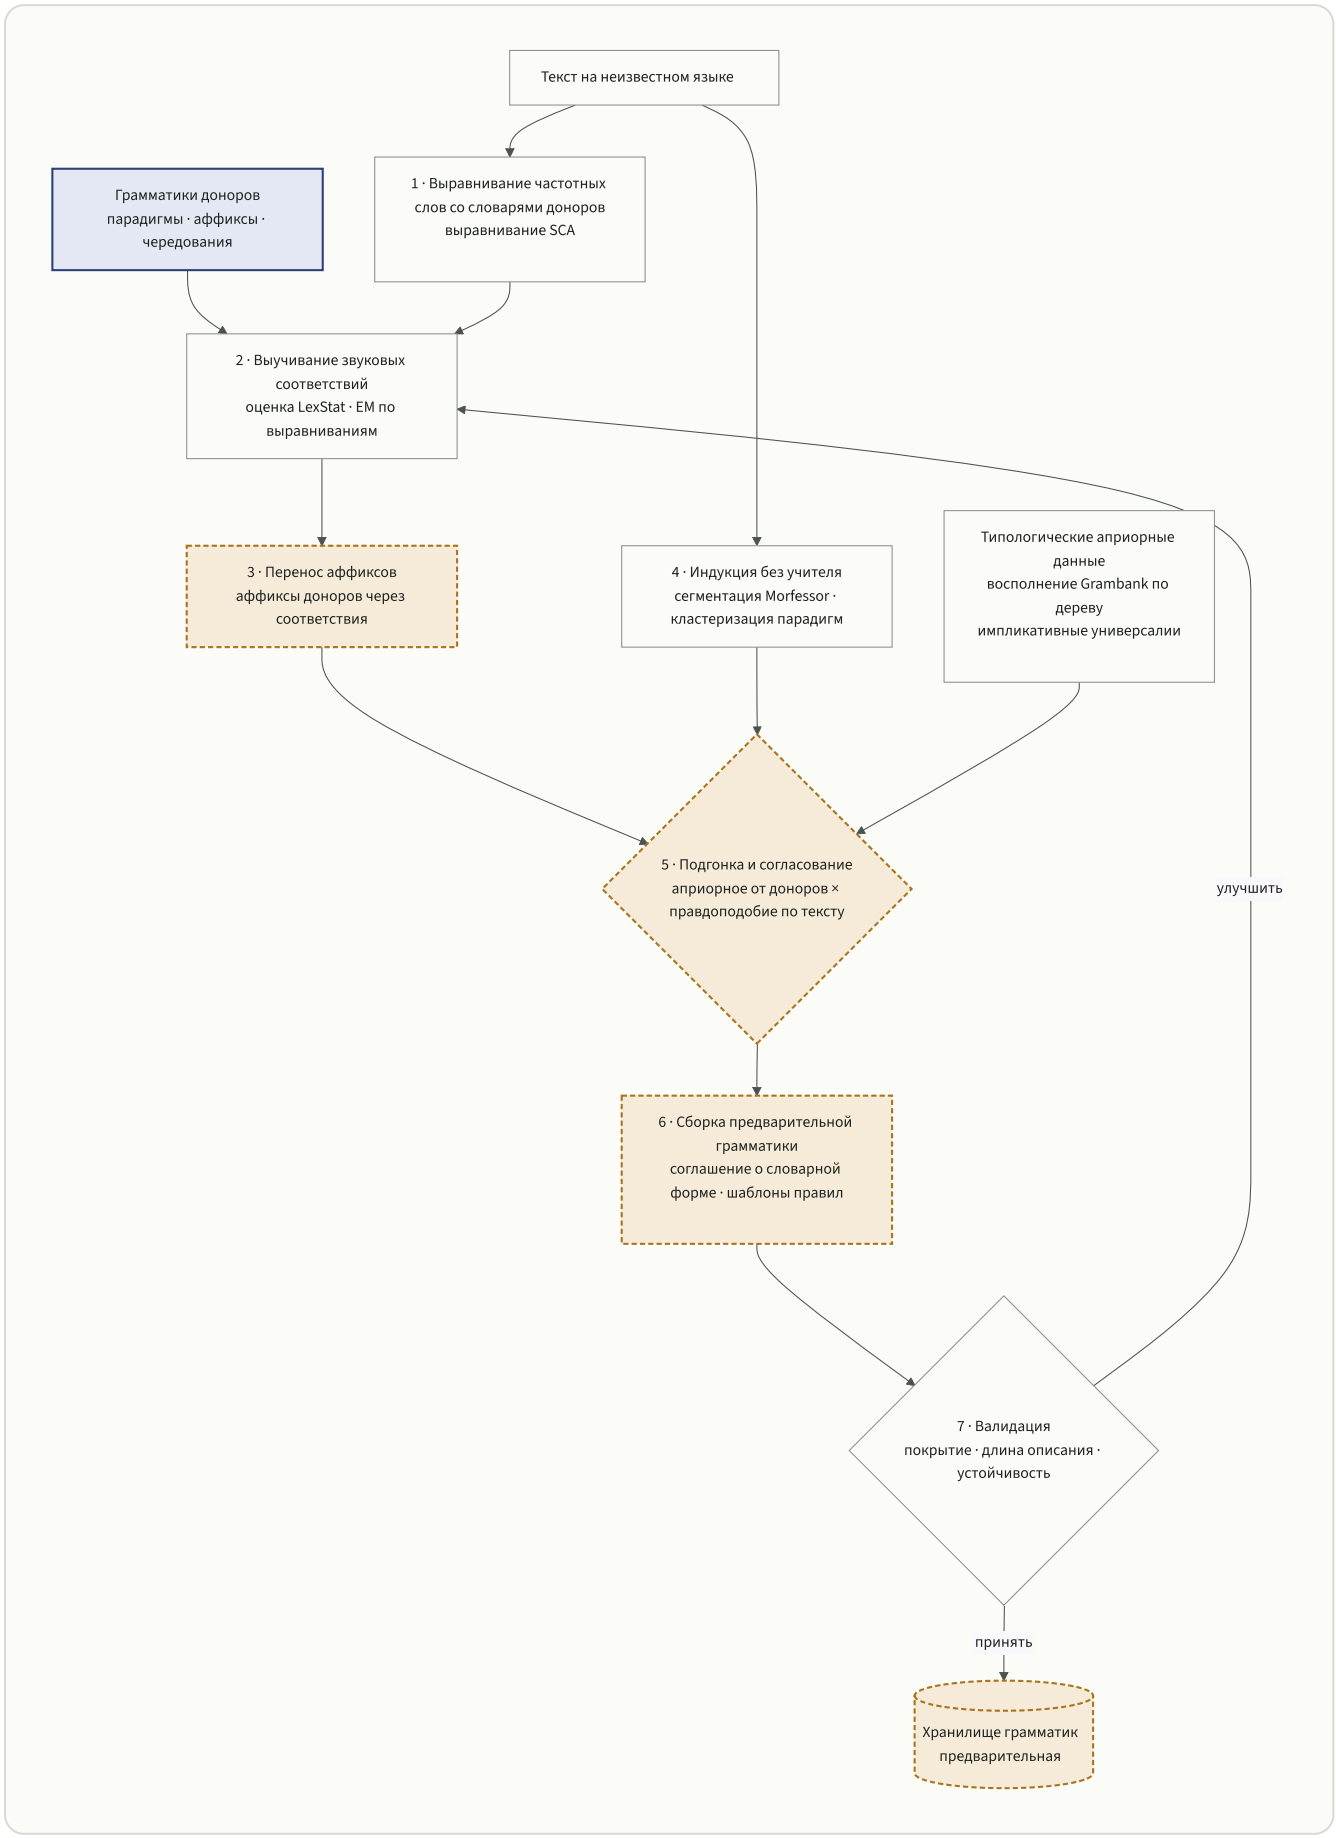


Рис. 3. Цикл порождения грамматики. Шаги 2–7 повторяются, пока покрытие и устойчивость грамматики перестают расти.

1 · Лексическое выравнивание

2 000 самых частотных словоформ неизвестного текста выравниваются со словарями доноров методом выравнивания по звуковым классам (SCA), который сравнивает слова по классам сходных звуков, а не по точным буквам. Если орфография не фонематическая, сначала обе стороны переводятся в МФА (в духе Epitran). На следующий шаг попадают только пары выше порога сходства.

2 · Звуковые соответствия

По выровненным парам система строит таблицу соответствий: какой звук донора каким звуком выступает в неизвестном языке и в каком контексте (например, p донора → f в начале слова; k → tʃ перед передними гласными). Применяется принцип LexStat: соответствие учитывается, только если оно повторяется в множестве пар слов гораздо чаще, чем в случайно перемешанных парах, — это отсеивает случайные совпадения и большую часть заимствований. Оценка — цикл EM: соответствия переоценивают выравнивания, улучшенные выравнивания уточняют соответствия. Если доноров несколько, шаблоны соответствий выводятся для всех совместно, что надёжнее попарных таблиц.

3 · Перенос аффиксов

Каждый аффикс каждой парадигмы донора пропускается через таблицу соответствий, что даёт предсказанные аффиксы целевого языка с вероятностями. Предсказание сохраняется, если предсказанная цепочка действительно встречается на правом (суффикс) или левом (префикс) краю многих разных словоформ целевого текста. Например, если донор выражает множественное число через `-at`, а таблица отображает a → e, система ищет продуктивный `-et` в целевом тексте.

4 · Индукция без учителя

Параллельно Morfessor FlatCat сегментирует целевые слова на основы и аффиксы, а кластеризация парадигм объединяет слова с общей основой и разными наборами аффиксов. Этот шаг видит только целевой текст, поэтому находит и ту морфологию, которой у доноров нет.

5 · Подгонка и согласование

Перенесённые аффиксы — априорное знание, индуцированная сегментация — свидетельство. Гипотеза оценивается по тому, насколько она сокращает описание корпуса (минимальная длина описания: грамматика плюс корпус, закодированный с её помощью). Спорные случаи решают типологические априорные данные: недостающие признаки Grambank целевого языка восполняются по его месту в дереве (ближайшие соседи, взвешенные филогенетически), а импликативные универсалии исключают маловероятные сочетания. При равновесии свидетельств действует априорное предпочтение суффиксации, поскольку суффиксация в языках мира встречается гораздо чаще префиксации.

6 · Сборка

Принятые аффиксы и чередования организуются в парадигмы и записываются как шаблоны lingua-rules. Соглашение о лемме (какая форма считается словарной: именительный падеж единственного числа, инфинитив, 3-е лицо единственного числа…) берётся у ближайшего донора, потому что так принято в грамматиках этой семьи. Каждое правило хранит происхождение (перенесено от какого донора, индуцировано или и то и другое), уверенность и число подтверждающих словоформ.

7 · Валидация и итерации

Грамматика оценивается по самому целевому тексту: доля токенов, получивших разбор (покрытие), длина описания, устойчивость правил при бутстрэп-перевыборке текста и согласованность обратной генерации (формы, порождённые из лемм, должны встречаться в тексте). Слабые правила отбрасываются или переоцениваются, и цикл повторяется. Итоговая грамматика сохраняется как *предварительная*; проверенной она становится только после экспертизы.

```
# Уровень C: вывод предварительной грамматики неизвестного языка U
def generate_grammar(U_text, donors, position):
    words = frequent_types(U_text, 2000)
    induced = morfessor_flatcat(U_text) + paradigm_clusters(U_text)
    priors  = impute_grambank(position) + universals()
    corr = init_correspondences()                                  # тождество + частые
звуковые изменения
    for it in range(MAX_ITER):
        pairs = [align_sca(w, lexicon[d]) for d in donors for w in words]
        pairs = [p for p in pairs if lexstat_score(p, corr) > TAU_ALIGN]
        corr  = estimate_correspondences(pairs, shuffled_baseline=True)    # шаг EM
        transferred = [map_affix(a, corr) for d in donors for a in affixes(d)]
        transferred = [a for a in transferred if edge_support(a, U_text) ⩾ MIN_TYPES]
        grammar = fit_mdl(prior=transferred, evidence=induced, typology=priors)
        score = validate(grammar, U_text)                          # покрытие, MDL,
устойчивость
        if score.gain < EPS:
            break
    grammar.lemma_convention = lemma_convention(closest(donors))
    return grammar.with_status("provisional", provenance=donors, confidence=score)
```

Законы языковой эволюции, на которые опирается система

«Общие лингвистические законы» конкретизируются как пять видов знаний, каждый из которых хранится как данные, а не как вручную написанный код:

ПРИНЦИП	КАК ЗАКОДИРОВАН	ГДЕ ИСПОЛЬЗУЕТСЯ
Регулярность звуковых изменений: изменение затрагивает все слова с тем же звуком в том же окружении	Таблицы соответствий, выученные EM; принимаются только регулярно повторяющиеся соответствия	Шаги 1–3
Направленные тенденции звуковых изменений (лениция, палатализация перед передними гласными, оглушение на конце слова, редукция гласных, ассимиляция)	Априорные вероятности типов изменений по базам засвидетельствованных звуковых изменений	Инициализация и регуляризация таблицы соответствий
Генеалогическое наследование: родственные языки сохраняют морфологию общего предка; устойчивые признаки меняются медленно	Дерево Glottolog; восполнение признаков с весами по расстоянию в дереве	Ранжирование доноров, типологические априорные данные
Типологические универсалии: импликативные тенденции (например, языки с глаголом в конце обычно имеют послелоги; предпочтение суффиксации)	Ограничения и априорные распределения над признаками Grambank/WALS	Шаг 5
Пути грамматикализации: грамматические показатели развиваются из лексических слов по повторяющимся путям (например, «идти» → будущее время)	Отображения «источник → результат» для интерпретации аффиксов с неясным значением	Приписывание грамматических признаков индуцированным аффиксам

> Нейросетевые модели реконструкции (предсказание рефлексов когнатов, реконструкция праформ) могут заменить EM-обучение соответствий, когда для семьи накопится достаточно наборов когнатов: именно они стали сильнейшими системами на соревновании SIGTYP 2022. EM-обучение остаётся запасным вариантом для семей с малым объёмом данных.

Вход и выход

Один и тот же JSON-контракт обслуживает все уровни, поэтому вызывающей стороне не нужно знать, как получена лемма:

```
POST /lemmatize
{ "text": "Текст на языке кхариа или любом другом…", "hint_language": null }

200 OK
{
  "segments": [
    { "span": [0, 118],
      "language": { "glottocode": "khar1287", "iso639_3": "khr", "status": "known",
                    "confidence": 0.93, "embedded": null },
      "tier": "B",
      "grammar": { "id": "khar1287@2026-09-27", "status": "provisional",
                   "sources": ["catalog:2932", "induced"] },
      "tokens": [
        { "form": "…", "lemma": "…", "pos": "NOUN", "features": "Case=Obl|Number=Sing",
          "confidence": 0.81, "rule": "noun_obl_sg", "origin": "extracted" }
      ] }
  ]
}
```

Для неизвестного языка `language.status` равен `"unknown"`, а блок дополняется полями `donors` (ранжированные родственники с оценками) и `tree_position` (оценённый узел Glottolog).

Соответствие нашей инфраструктуре

Большая часть нужных знаний уже собирается на corpus-host:

ЭЛЕМЕНТ ПРОЕКТА	ИМЕЮЩИЙСЯ РЕСУРС	СОСТОЯНИЕ (27.09.2026)
Перечень языков и генеалогическое дерево	Список языков Glottolog на сервере	8 624 языка
Грамматики для уровня B	Каталог документов, поле «описываемый язык»	1 718 языков с подтверждённой грамматикой
Формат хранилища грамматик	lingua-rules (шаблоны правил ASP, генераторы, эталонные тесты)	Проверенные правила для английского, немецкого, русского, финского
Извлечение правил и модель ранжирования родственников	Локальная LLM на RTX 5090 (qwen3.8, контекст 128k)	Работает; уже классифицирует документы каталога
Поиск грамматик	REST API каталога корпуса (`/corpus/api/documents?described=…`)	Работает, HTTPS
Тексты для индукции и n-граммных профилей	Языковой корпус и коллекции грамматик	≈ 290 000 зарегистрированных документов

Недостающие части: модели GlotLID/OpenLID, данные UD и UniMorph, векторы Grambank/URIEL+ и реализация модуля обучения соответствий (LingPy предоставляет выравнивание SCA и LexStat).

Оценка качества

- **Распознавание:** точность и macro-F1 на отложенных тестовых наборах в стиле GlotLID/FLORES; отказ для неизвестных проверяется скрытием целых языков от классификатора: они должны отвергаться, а семья скрытого языка — стоять первой среди предложенных родственников.
- **Уровень A:** точность лемм на тестовых трибанках Universal Dependencies в сравнении со Stanza/UDPipe.
- **Уровень C методом имитации:** решающая проверка. Берётся язык, у которого *есть* проверенная грамматика и трибанк, делается вид, что он неизвестен, его грамматика выводится только из родственников, и точность лемм сравнивается с трибанком. Повторение по схеме «один язык исключён» для разных семей показывает, как точность предварительных грамматик зависит от степени родства и объёма текста.
- **Уровень B:** извлечённые правила проверяются на глоссированных примерах из самой грамматики, затем — на трибанке, если он есть.

Ограничения и риски

- **Близкие родственники путают распознавание.** Взаимопонятные варианты (например, боснийский/хорватский/сербский, малайский/индонезийский) регулярно путаются системами LID; проверка на выброс и второй голос уменьшают, но не устраняют проблему.
- **Соответствиям нужны данные.** Надёжное обучение соответствий требует порядка сотни и более пар когнатов; очень короткие тексты дают только n-граммные и типологические сигналы.
- **Заимствования и контакты.** Заимствованная лексика может сделать язык похожим на соседа; проверка регулярности LexStat и типологический сигнал противодействуют этому, но не полностью.
- **Изоляты и глубокие семьи.** Без близких родственников уровень C сводится к индукции без учителя и априорным данным. Соревнование SIGMORPHON 2020 показало, что восстановление парадигм без учителя остаётся в значительной мере нерешённой задачей, поэтому ожидания для изолятов должны быть скромными.
- **Орфография — не фонология.** Соответствия выучиваются на звуках; для глубоких или непоследовательных орфографий нужен перевод графем в фонемы, которого может не быть.
- **Предварительные грамматики могут уверенно ошибаться.** У каждой выведенной леммы есть происхождение и уверенность; потребители должны фильтровать по статусу.

Литература

1. Kargaran et al. (2023). GlotLID: Language Identification for Low-Resource Languages. EMNLP. Код: github.com/cisnlp/GlotLID
2. OpenLID-v3 (2026). Improving the Precision of Closely Related Language Identification — an experience report.
3. Kargaran et al. (2024). MaskLID: Code-Switching Language Identification through Iterative Masking. ACL.
4. Lin et al. (2019). Choosing Transfer Languages for Cross-Lingual Learning (LangRank). ACL.
5. List (2012). LexStat: Automatic detection of cognates in multilingual wordlists; List (2019). Automatic Inference of Sound Correspondence Patterns across Multiple Languages. Computational Linguistics.
6. Bouchard-Côté, Hall, Griffiths, Klein (2013). Automated reconstruction of ancient languages using probabilistic models of sound change. PNAS 110(11).
7. List et al. (2022). The SIGTYP 2022 Shared Task on the Prediction of Cognate Reflexes; Kim et al. (2023). Cognate Transformer for Automated Phonological Reconstruction and Cognate Reflex Prediction.
8. Kann et al. (2020). The SIGMORPHON 2020 Shared Task on Unsupervised Morphological Paradigm Completion.
9. Grönroos et al. (2014). Morfessor FlatCat: an HMM-based method for unsupervised and semi-supervised learning of morphology. COLING. См. также Morphological Segmentation for Low Resource Languages (LREC 2020).
10. Kanerva et al. Universal Lemmatizer: a sequence-to-sequence model for lemmatizing Universal Dependencies treebanks. Natural Language Engineering.

11. Chaudhary et al. (2022). AutoLEX: An Automatic Framework for Linguistic Exploration; Chaudhary et al. (2020). Automatic Extraction of Rules Governing Morphological Agreement.
12. Tanzer et al. (2024). A Benchmark for Learning to Translate a New Language from One Grammar Book (MTOB). ICLR; Aycock et al. (2024). Can LLMs really learn to translate a low-resource language from one grammar book?
13. Skirgård et al. (2023). Grambank reveals the importance of genealogical constraints on linguistic diversity. Science Advances; Bjerva et al. (2020). SIGTYP 2020 Shared Task: Prediction of Typological Features; The Role of Typological Feature Prediction in NLP and Linguistics (Computational Linguistics, 2024).
14. Hammarström et al. Glottolog (glottolog.org) — перечень языков и генеалогическая классификация.

Проект для обсуждения. Цифры в разделе «Соответствие нашей инфраструктуре» взяты из каталога corpus-host на 27 сентября 2026 г.